

Atividade 2 – Pipeline de Data Lake com Amazon S3 e Amazon Athena

Relatório de entrega · Ingestão, Data Quality, quarentena, camadas Raw/Silver/Gold e auditoria no Athena

Aluno	Gabriel G. Ribeiro
RA	10781021
Curso	MBA em Inteligência de Dados & Analytics para Negócios
Disciplina	Data Lakes
Professor	Yuri Menezes
Data	13/09/2026
Repositório	https://github.com/gabrielgribeiro/datalake-gabrielribeiro-pos-mba

1. O que foi construído

Pipeline em Python (pandas, pyarrow e boto3) que simula o ciclo completo de dados de vendas em um data lake na AWS, executado na conta do AWS Academy (região us-east-1):

- **Ingestão (Raw):** geração de massa sintética de clientes, produtos e pedidos com anomalias injetadas de propósito (quantidade negativa, quantidade zero, cliente e produto inexistentes), gravada em CSV com partição Hive `ingest_date=YYYY-MM-DD`.
- **Data Quality e quarentena:** descarte de pedidos com quantidade menor ou igual a zero e de chaves inexistentes nas dimensões; registros rejeitados gravados em JSON com o motivo em

Estrutura gerada no S3

```
s3://datalake-gabrielribeiro-pos-mba/  
├─ raw/  
│   ├── clientes/ingest_date=2026-09-13/clientes.csv  
│   ├── produtos/ingest_date=2026-09-13/produtos.csv  
│   └── pedidos/ingest_date=2026-09-13/pedidos.csv  
├─ quarantine/  
│   └── pedidos_rejeitados/data=2026-09-13/rejeitados.json  
├─ processed/  
│   └── fato_vendas/ingest_date=2026-09-13/fato_vendas.snappy.parquet  
├─ gold/  
│   └── agg_vendas_uf_categoria/ingest_date=2026-09-13/
```

quarantine/pedidos_rejeitados/data=YYYY-MM-DD/rejeitados.json .

- **Silver:** JOIN de pedidos válidos com clientes e produtos, cálculo de `valor_total = quantidade x preco` e persistência em Parquet/Snappy em `processed/fato_vendas/` .
- **Gold:** agregação por UF e categoria com `qtd_pedidos`, `qtd_itens`, `receita_total`, `ticket_medio`, clientes e produtos distintos, em Parquet/Snappy em `gold/agg_vendas_uf_categoria/` .
- **Auditoria no Athena:** tabelas externas para as quatro camadas, queries com as pseudo-colunas `"$path"` e `"$file_size"` e conciliação `Raw = Silver + Quarentena` .

```
|      agg_vendas_uf_categoria.snappy.parquet  
└─ athena-results/
```

2. Resultado da execução

Métrica	Valor
Pedidos gerados na Raw	2.000
Pedidos aprovados (Silver)	1.760
Pedidos em quarentena	240
Rejeições por quantidade inválida	115
Rejeições por cliente inexistente	65
Rejeições por produto inexistente	60
Linhas na Gold (UF x categoria)	72
Redução de tamanho CSV para Parquet/Snappy	53,76%
Conciliação Raw = Silver + Quarentena	OK (diferença = 0)

Como executar (resumo)

```
pip install -r requirements.txt
python run_pipeline.py                # modo local, sem AWS
python run_pipeline.py --target s3 --bucket SEU-BUCKET --criar-bucket
                                     # grava no Amazon S3
python -m src.athena_setup --bucket SEU-BUCKET --executar
                                     # cria banco e tabelas no Athena
python -m tests.test_data_quality    # testes das regras de qualidade
```

As instruções completas, as decisões de arquitetura e os scripts SQL (01 a 05) estão no README e na pasta `docs/` do repositório.

3. Onde cada critério de avaliação é atendido

Critério	Peso	Onde está no repositório	Evidência
Ingestão e particionamento S3	20%	<code>src/ingest_raw.py</code>	Prints 1 e 1b
Data Quality e quarentena	25%	<code>src/process_silver.py</code> , <code>tests/test_data_quality.py</code>	Prints 5 e 5b
Camadas Silver e Gold	30%	<code>src/process_silver.py</code> , <code>src/build_gold.py</code>	Prints 3, 3b e 6
Auditoria e validação Athena	25%	<code>sql/02</code> a <code>sql/05</code> , <code>src/athena_setup.py</code>	Prints 2, 3 e 4

Print 1 – Estrutura de pastas no Amazon S3

Bucket `datalake-gabrielribeiro-pos-mba` com as pastas `raw/`, `quarantine/`, `processed/`, `gold/` e `athena-results/`.

Amazon S3

Buckets

Buckets de uso geral

Buckets de diretório

Buckets de tabela

Buckets de vetores

Arquivos

Sistemas de arquivos

Gerenciamento de acesso e segurança

Pontos de acesso

Pontos de acesso para FSx

Access Grants

IAM Access Analyzer

Gerenciamento e insights de armazenamento

Lente de Armazenamento

Operações em lotes

Configurações de conta e organização

AWS Marketplace para S3

datalake-gabrielribeiro-pos-mba

Informações

Objetos

Metadados

Propriedades

Permissões

Métricas

Gerenciamento

Sistemas de arquivos

Pontos de acesso

Objetos (5)

Copiar URI do S3

Copiar URL

Fazer download

Abrir

Excluir

Ações

Criar pasta

Carregar

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

☐	Nome	Tipo	Última modificação	Tamanho	Classe de armazenamento
☐	athena-results/	Pasta	-	-	-
☐	gold/	Pasta	-	-	-
☐	processed/	Pasta	-	-	-
☐	quarantine/	Pasta	-	-	-
☐	raw/	Pasta	-	-	-

CloudShell

Kit de ferramentas de agentes para a AWS

Comentários

© 2026, Amazon Web Services, Inc. ou suas afiliadas.

Privacidade

Termos

Preferências de cookies

Print 1b – Particionamento Hive na camada Raw

Pasta `raw/pedidos/ingest_date=2026-09-13/`, no padrão Hive exigido no enunciado.

The screenshot shows the Amazon S3 console interface. The breadcrumb navigation indicates the path: **Amazon S3** > **Buckets** > **datalake-gabrielribeiro-pos-mba** > **raw/** > **pedidos/**. The left sidebar contains navigation options: Buckets, Arquivos, Gerenciamento de acesso e segurança, and Gerenciamento e insights de armazenamento. The main content area shows the 'pedidos/' bucket with a 'Objetos (1)' section. A table lists the object 'ingest_date=2026-09-13/' with a type of 'Pasta'. The bottom of the page includes a footer with '© 2026, Amazon Web Services, Inc. ou suas afiliadas.' and links for 'Privacidade', 'Termos', and 'Preferências de cookies'.

Amazon S3 > Buckets > datalake-gabrielribeiro-pos-mba > raw/ > pedidos/

Amazon S3

- ▼ Buckets
 - Buckets de uso geral
 - Buckets de diretório
 - Buckets de tabela
 - Buckets de vetores
- ▼ Arquivos
 - Sistemas de arquivos
- ▼ Gerenciamento de acesso e segurança
 - Pontos de acesso
 - Pontos de acesso para FSx
 - Access Grants
 - IAM Access Analyzer
- ▼ Gerenciamento e insights de armazenamento
 - Lente de Armazenamento
 - Operações em lotes
- Configurações de conta e organização
- AWS Marketplace para S3

pedidos/

Objetos | Propriedades

Objetos (1)

Os objetos são as entidades fundamentais armazenadas no Amazon S3. Você pode usar o [inventário do Amazon S3](#) para obter uma lista de todos os objetos em seu bucket. Para outras pessoas acessarem seus objetos, você precisará conceder permissões explicitamente a eles. [Saiba mais](#)

Localizar objetos por prefixo

☐	Nome	Tipo	Última modificação	Tamanho	Classe de armazenamento
☐	ingest_date=2026-09-13/	Pasta	-	-	-

CloudShell Kit de ferramentas de agentes para a AWS Comentários

© 2026, Amazon Web Services, Inc. ou suas afiliadas. Privacidade Termos Preferências de cookies

Print 2 – Query Q4.1: pseudo-colunas "\$path" e "\$file_size"

Arquivo físico de origem, tamanho em bytes e contagem de registros da camada Raw.

The screenshot displays the Amazon Athena console interface. On the left, the 'Dados' sidebar shows the data source as 'AwsDataCatalog', the catalog as 'Nenhum', and the database as 'datalake_mackenzie'. Below this, a list of tables is visible, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main area shows a SQL query for 'Consulta 1' with the following text:

```
1 SELECT
2   "$path" AS arquivo_origem,
3   "$file_size" AS tamanho_bytes,
4   ROUND("$file_size" / 1024.0, 2) AS tamanho_kb,
5   ingest_date,
6   COUNT(*) AS qtd_registros
7 FROM datalake_mackenzie.raw_pedidos
8 GROUP BY "$path", "$file_size", ingest_date
9 ORDER BY ingest_date
```

Below the query editor, the 'Resultados da consulta' tab is active, showing a green status bar indicating the query is 'Concluído'. The execution statistics are: 'Tempo na fila: 68 ms', 'Tempo de execução: 673 ms', and 'Dados verificados: 96.10 KB'. The results table has 1 row and 6 columns: '#', 'arquivo_origem', 'tamanho_bytes', 'tamanho_kb', 'ingest_date', and 'qtd_registros'. The data row shows a file path 's3://datalake-gabrielribeiro-pos-mba/raw/pedidos/ingest_date=2026-09-13/pedidos.csv', a size of 98406 bytes, 96.1 KB, the date 2026-09-13, and a count of 2000 records.

#	arquivo_origem	tamanho_bytes	tamanho_kb	ingest_date	qtd_registros
1	s3://datalake-gabrielribeiro-pos-mba/raw/pedidos/ingest_date=2026-09-13/pedidos.csv	98406	96.1	2026-09-13	2000

The footer of the console shows the year '© 2026, Amazon Web Services, Inc. ou suas afiliadas' and links for 'Privacidade', 'Termos', and 'Preferências de cookies'.

Raw (CSV), Quarentena (JSON), Silver e Gold (Parquet/Snappy) com caminho e tamanho de cada arquivo.

CloudShell Kit de ferramentas de agentes para a AWS Comentários © 2025, Amazon Web Services, Inc. ou suas afiliadas. Privacidade Termos Preferências de cookie

Print 3b – Query Q4.3: ganho de compressão CSV x Parquet/Snappy

Redução de 53,76% no tamanho do arquivo da Raw para a Silver.

The screenshot displays the Amazon Athena console interface. On the left, the 'Dados' sidebar shows the data source as 'AwsDataCatalog', the catalog as 'Nenhum', and the database as 'datalake_mackenzie'. The 'Tabelas e visões' section lists several tables, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main area shows a SQL query for 'Consulta 1' with the following code:

```
1 - WITH raw_fisico AS (  
2   SELECT DISTINCT "$path" AS arquivo, "$file_size" AS bytes  
3   FROM datalake_mackenzie.raw_pedidos  
4 ),  
5 silver_fisico AS (  
6   SELECT DISTINCT "$path" AS arquivo, "$file_size" AS bytes  
7   FROM datalake_mackenzie.fato_vendas  
8 )  
9 SELECT  
10  (SELECT SUM(bytes) FROM raw_fisico) AS bytes_raw_csv,  
11  (SELECT SUM(bytes) FROM silver_fisico) AS bytes_silver_parquet,  
12  ROUND(100.0 * (1 - CAST((SELECT SUM(bytes) FROM silver_fisico) AS double)  
13    / (SELECT SUM(bytes) FROM raw_fisico)), 2) AS reducao_percentual
```

Below the query, the 'Resultados da consulta' tab is active, showing a status of 'Concluído'. The execution details are: 'Tempo na fila: 95 ms', 'Tempo de execução: 954 ms', and 'Dados verificados: 96.10 KB'. The results table has 1 row and 4 columns: '#', 'bytes_raw_csv', 'bytes_silver_parquet', and 'reducao_percentual'. The single row of data shows values 1, 98406, 45502, and 53.76.

#	bytes_raw_csv	bytes_silver_parquet	reducao_percentual
1	98406	45502	53.76

The footer of the console shows '© 2026, Amazon Web Services, Inc. ou suas afiliadas.' along with links for 'Privacidade', 'Termos', and 'Preferências de cookies'.

Print 4 – Query Q5.1: conciliação de integridade Raw = Silver + Quarentena

2000 = 1760 + 240, diferença 0, status "OK - INTEGRIDADE CONFIRMADA".

The screenshot displays the Amazon Athena console interface. On the left, the 'Dados' (Data) sidebar shows the data source as 'AwsDataCatalog', the catalog as 'Nenhum', and the database as 'datalake_mackenzie'. Below this, a list of tables is shown, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main editor area contains a SQL query for 'Consulta 1'.

```
1 - WITH total_raw AS (  
2   SELECT COUNT(*) AS qtd FROM datalake_mackenzie.raw_pedidos  
3 ),  
4 total_silver AS (  
5   SELECT COUNT(*) AS qtd FROM datalake_mackenzie.fato_vendas  
6 ),  
7 total_quarentena AS (  
8   SELECT COUNT(*) AS qtd FROM datalake_mackenzie.quarentena_pedidos_rejeitados  
9 )  
10 SELECT  
11   r.qtd AS total_raw,  
12   s.qtd AS total_silver,  
13   q.qtd AS total_quarentena,  
14   (s.qtd + q.qtd) AS soma_silver_quarentena,  
15   (r.qtd - (s.qtd + q.qtd)) AS diferenca,  
16   CASE WHEN r.qtd = s.qtd + q.qtd  
17     THEN 'OK - INTEGRIDADE CONFIRMADA'  
18     ELSE 'DIVERGENCIA - INVESTIGAR'  
19   END AS status_conciliacao  
20 FROM total_raw r, total_silver s, total_quarentena q
```

Below the query editor, the 'Executar novamente' (Execute again) button is visible. The 'Resultados da consulta' (Query results) section shows the query status as 'Concluído' (Completed). The execution statistics indicate a time of 1.299 seconds and 163.92 KB of data verified. The results are displayed in a table with 8 columns: #, total_raw, total_silver, total_quarentena, soma_silver_quarentena, diferenca, and status_conciliacao. The first row shows the results for the query.

#	total_raw	total_silver	total_quarentena	soma_silver_quarentena	diferenca	status_conciliacao
1	2000	1760	240	2000	0	OK - INTEGRIDADE CONFIRMADA

Print 5 – Query Q5.2: rejeições por motivo

Quantidade inválida (115), cliente inexistente (65) e produto inexistente (60).

The screenshot shows the Amazon Athena console interface. On the left, the 'Dados' sidebar is visible with settings for 'Fonte de dados' (AwsDataCatalog), 'Catálogo' (Nenhum), and 'Banco de dados' (datalake_mackenzie). Below this, a list of tables is shown, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main area displays a SQL query for 'Consulta 1' which calculates the percentage of records for different rejection reasons. The query is as follows:

```
1 SELECT
2   motivo_rejeicao,
3   COUNT(*)
4   ROUND(100.0 * COUNT(*) / SUM(COUNT(*) OVER (), 2)
5 FROM datalake_mackenzie.quarentena_pedidos_rejeitados
6 GROUP BY motivo_rejeicao
7 ORDER BY qtd_registros DESC
```

The query results are shown in a table with 4 columns: '#', 'motivo_rejeicao', 'qtd_registros', and 'percentual'. There are 3 rows of data:

#	motivo_rejeicao	qtd_registros	percentual
1	QUANTIDADE_INVALIDA: quantidade menor ou igual a zero	115	47.92
2	CLIENTE_INEXISTENTE: cliente_id nao encontrado na dimensao clientes	65	27.08
3	PRODUTO_INEXISTENTE: product_id nao encontrado na dimensao produtos	60	25.0

At the bottom of the console, there is a footer with links to 'CloudShell', 'Kit de ferramentas de agentes para a AWS', and 'Comentários', along with copyright information for Amazon Web Services, Inc. and links for 'Privacidade', 'Termos', and 'Preferências de cookies'.

Print 5b – Query Q5.3: nenhuma anomalia na camada Silver

Zero registros com quantidade menor ou igual a zero, zero clientes órfãos e zero produtos órfãos.

The screenshot displays the Amazon Athena console interface. On the left, the 'Dados' (Data) sidebar shows the data source as 'AwsDataCatalog', the catalog as 'Nenhum', and the database as 'datalake_mackenzie'. Below this, a list of tables is visible, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main area shows a SQL query for 'Consulta 1' with the following code:

```
1 SELECT
2   SUM(CASE WHEN quantidade <= 0 THEN 1 ELSE 0 END) AS qtd_invalida_na_silver,
3   SUM(CASE WHEN cliente_id NOT IN (SELECT cliente_id FROM datalake_mackenzie.raw_clientes) THEN 1 ELSE 0 END) AS cliente_orfao_na_silver,
4   SUM(CASE WHEN product_id NOT IN (SELECT product_id FROM datalake_mackenzie.raw_produtos) THEN 1 ELSE 0 END) AS produto_orfao_na_silver
5 FROM datalake_mackenzie.fato_vendas
```

The query is executed, and the results are displayed under 'Resultados da consulta'. The status is 'Concluído' (Completed). The execution details show: 'Tempo na fila: 97 ms', 'Tempo de execução: 1.505 sec', and 'Dados verificados: 19.67 KB'. The results table has one row with the following values:

#	qtd_invalida_na_silver	cliente_orfao_na_silver	produto_orfao_na_silver
1	0	0	0

The footer of the console shows the copyright notice: '© 2026, Amazon Web Services, Inc. ou suas afiliadas.' and links for 'Privacidade', 'Termos', and 'Preferências de cookies'.

Print 6 – Query Q5.5: leitura analítica da camada Gold

Top 10 combinações de UF e categoria por receita, com métricas de negócio.

The screenshot displays the Amazon Athena console interface. On the left, the 'Dados' (Data) sidebar shows the data source as 'AwsDataCatalog', the catalog as 'Nenhum', and the database as 'datalake_mackenzie'. Below this, a list of tables is visible, including 'agg_vendas_uf_categoria', 'fato_vendas', 'quarentena_pedidos_rejeitados', 'raw_clientes', 'raw_pedidos', and 'raw_produtos'. The main area shows a SQL query for 'Consulta 1' that selects various metrics from the 'agg_vendas_uf_categoria' table, ordered by 'receita_total' in descending order, with a limit of 10. The query is executed, and the results are displayed in a table format. The table has 10 rows and 7 columns: '#', 'uf', 'categoria', 'qtd_pedidos', 'qtd_itens', 'receita_total', and 'clientes_distintos'. The results show the top 10 combinations of state and category by revenue.

Consulta 1 :

```
5 qtd_itens,  
6 receita_total,  
7 ticket_medio,  
8 clientes_distintos  
9 FROM datalake_mackenzie.agg_vendas_uf_categoria  
10 ORDER BY receita_total DESC  
11 LIMIT 10
```

SQL Ln 11, Col 9

Resultados da consulta | Estatísticas da consulta

Concluído | Tempo na fila: 113 ms | Tempo de execução: 602 ms | Dados verificados: 2.51 KB

Resultados (10)

#	uf	categoria	qtd_pedidos	qtd_itens	receita_total	ticket_medio	clientes_distintos
1	BA	Eletronicos	61	829	3161469.56	51827.37	22
2	RJ	Eletronicos	54	828	3137827.85	58107.92	16
3	SP	Eletronicos	59	745	2657858.05	45048.44	21
4	PE	Eletronicos	51	620	2194367.54	43026.81	21
5	GO	Eletronicos	45	589	2046141.75	45469.82	14
6	PR	Eletronicos	43	515	2029184.1	47190.33	16
7	SC	Informatica	26	405	1917274.02	73741.31	12
8	DF	Eletronicos	39	508	1892897.35	48535.83	15
9	PR	Informatica	33	443	1833215.92	55552.0	16
10	SC	Eletronicos	33	417	1805198.76	54702.99	12